Регуляризация линейной регрессии

Маргарита Широбокова

Product Owner R&D ELMA AI



образовательная платформа

Регуляризация линейной регрессии

Анализ результатов линейной регрессии



Уравнение регрессии

$$\hat{y} = f(w, x) = w_0 + w_1 \times x_1 + ... + w_k \times x_k$$

```
Где
```

 \hat{y} — целевая переменная, $(x_1, ..., x_k)$ — вектор признаков, $w_0, w_1, ..., w_k$ — параметры модели цели, как их ещё называют $w_1, ..., w_k$ — вектор весов, а число w_0 — свободный коэффициент, или сдвиг (bias)

Или компактная запись

$$\hat{y} = \langle x, w \rangle + w_0$$

Остатки регрессии

Сравнить предсказанные значения с реальными данными:

то есть сравнить у- и у

$$e = y-y-$$

у — реальное значение;

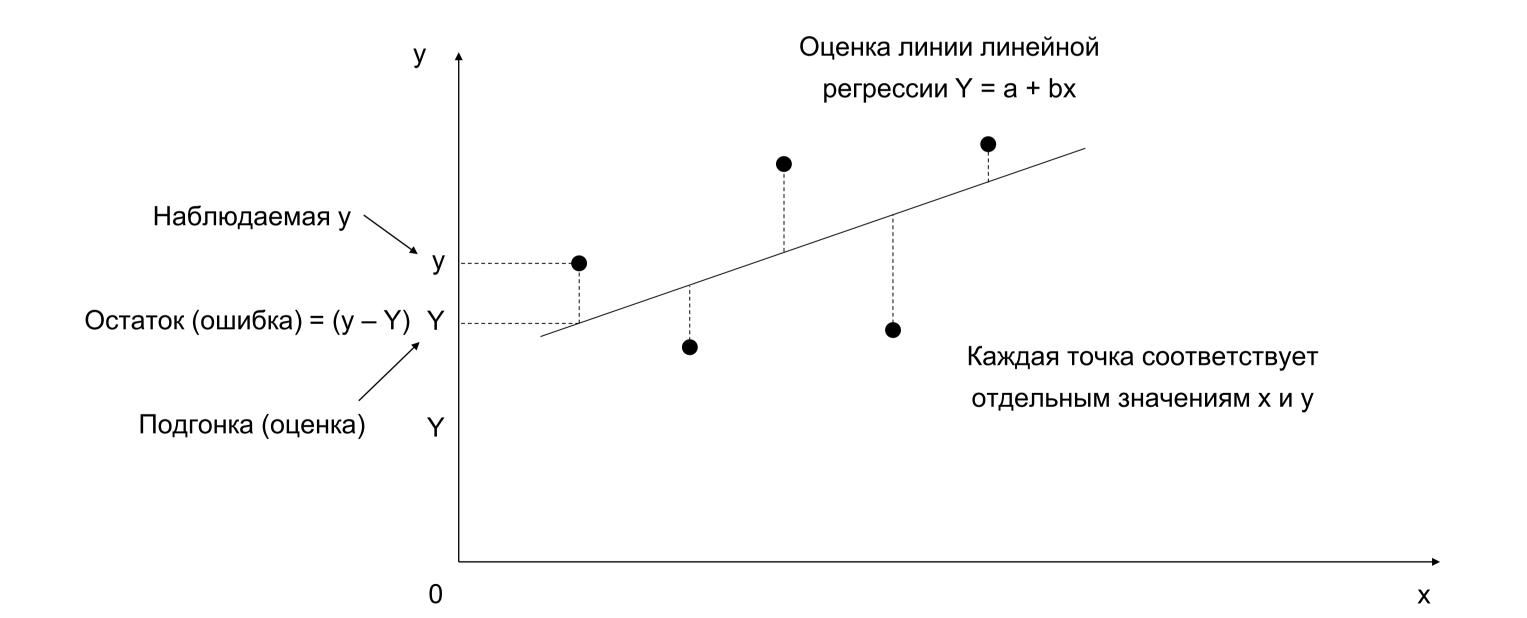
у- — предсказанное значение.

Остатки регрессии — это разности между реальными значениями и значениями, предсказанными регрессионной моделью.

В терминах матриц можно записать также:

$$e = y-y-= y-X (XTX)-1XTy$$

Остатки регрессии



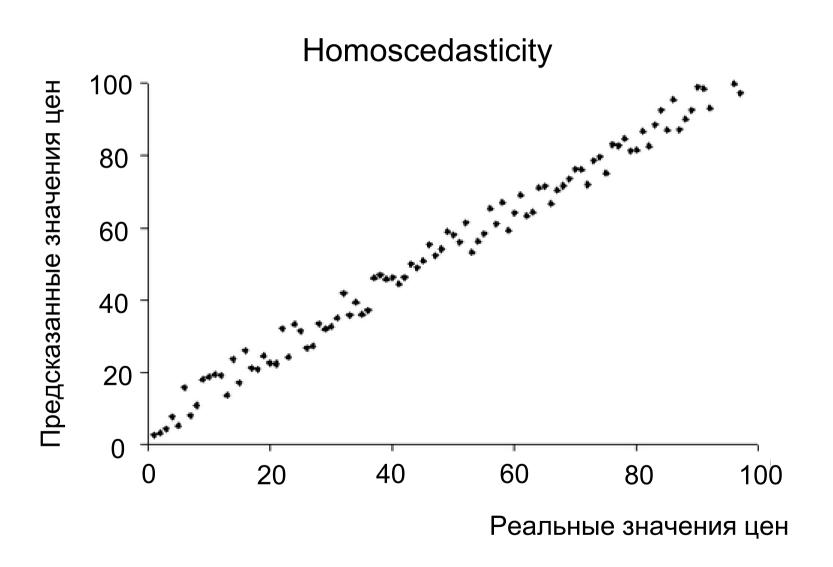
Гомоскедастичность

Гомоскедастичность — свойство, обозначающее постоянство дисперсии некоторой последовательности случайных величин.

Дисперсия (Variance) — это отклонение точек относительно прямой.

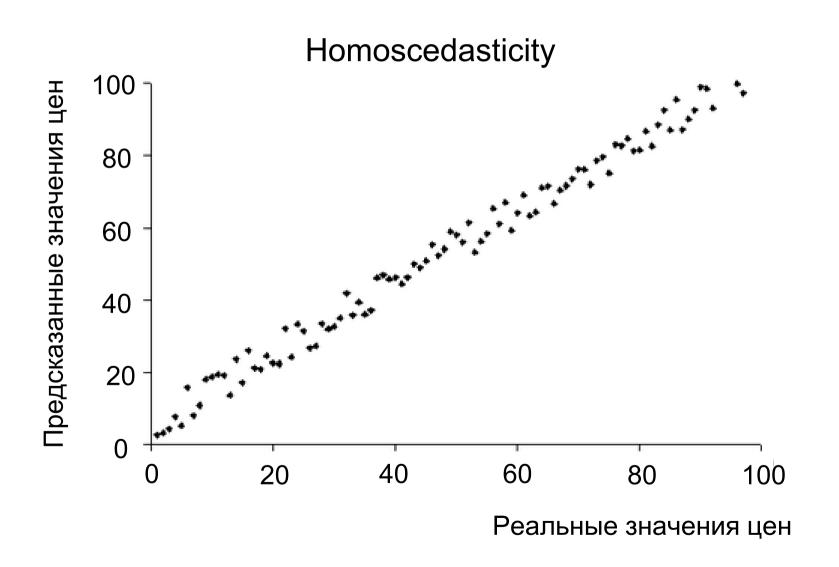
В нашем случае это означает, что дисперсия остатков регрессии должна быть однородной, стабильной для всех наблюдаемых объектов и во все моменты измерения.

Пример: цена на автомобиль



Пример гомоскедастичной вариативности

Пример: цена на автомобиль



Пример гомоскедастичной вариативности

Пример гетероскедастичности

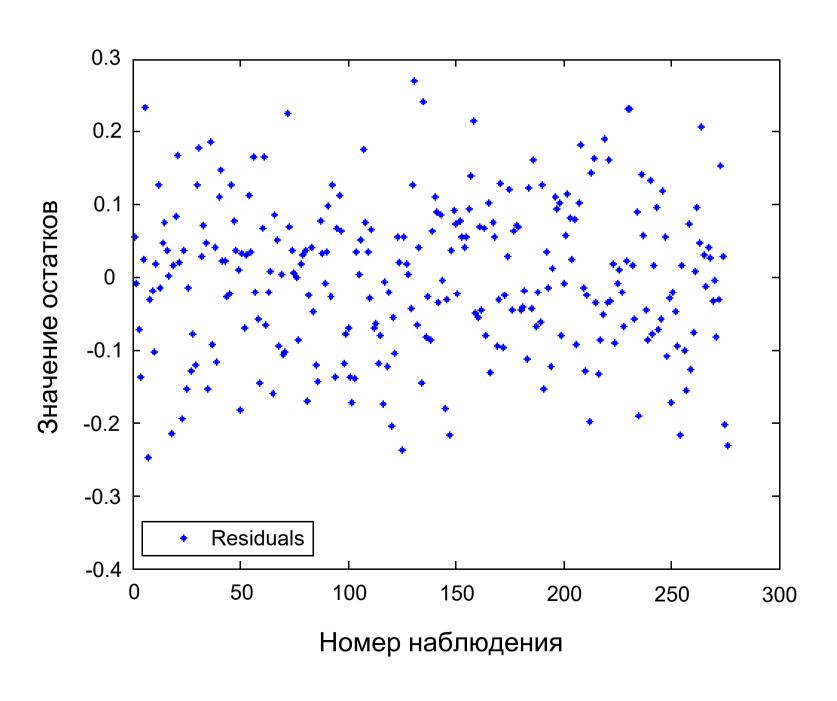
Гомоскедастичность и гетероскедастичность

Гомоскедастичность — свойство, обозначающее постоянство дисперсии некоторой последовательности случайных величин.

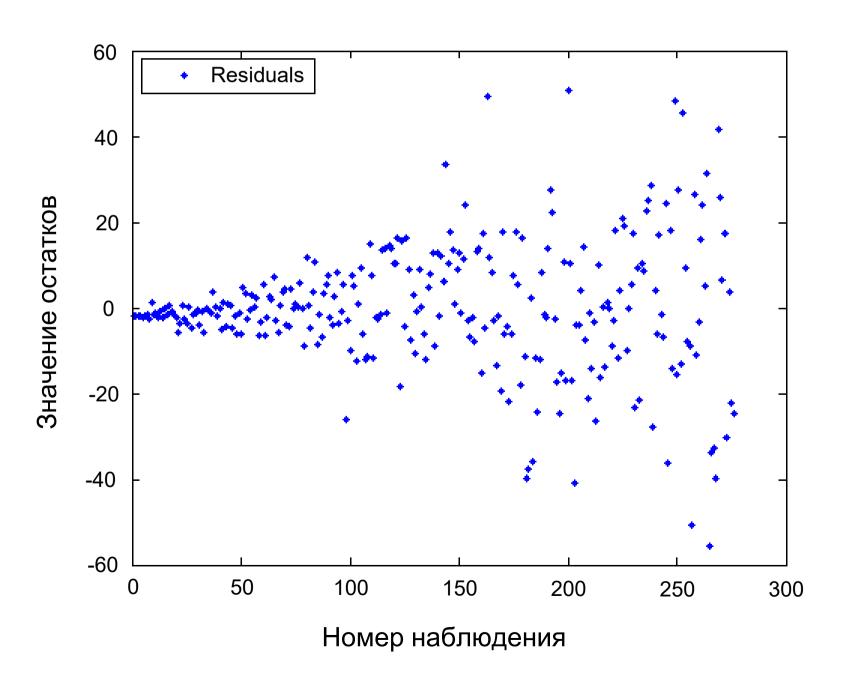
Гетероскедастичность — наоборот, неоднородность наблюдений, выражающуюся в неодинаковой, непостоянной дисперсии случайной ошибки регрессионной модели.

Если выбранная регрессионная модель хорошо описывает истинную зависимость, то остатки должны быть независимыми нормально распределёнными случайными величинами с нулевым средним и в их значениях должен отсутствовать тренд.

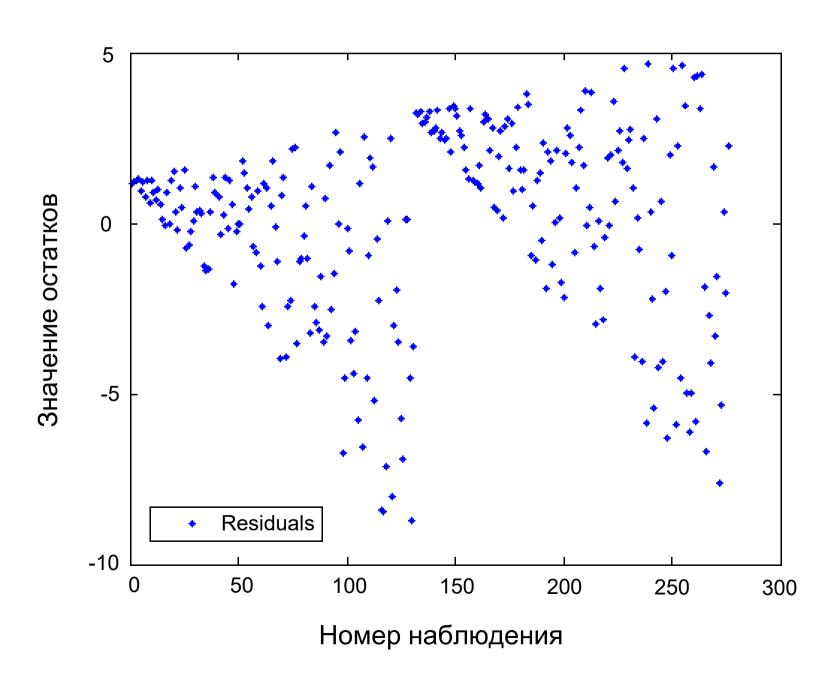
Гомоскедастичность



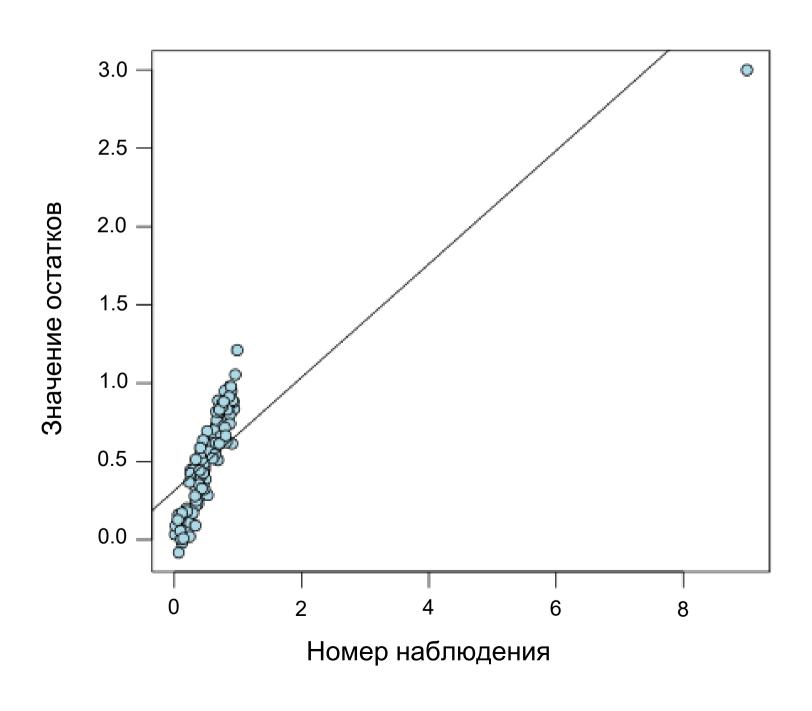
Гетероскедастичность



Гетероскедастичность



Пример с выбросом



Коэффициент детерминации R2

Коэффициент детерминации принимает значения от 0 до 1.

Чем ближе значение коэффициента к 1, тем сильнее зависимость.

Для приемлемых моделей — 0,5.

Для достаточно хороших моделей — 0,8.

Для идеальной модели — 1.

Коэффициент детерминации R2

Коэффициент детерминации находится по следующей формуле:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

где $SS_{res} = \sum_{i} e_{i}^{2} = \sum_{i} (y_{i} - \hat{y}_{i})^{2}$ — уже знакомая сумма квадратов остатков регрессии

a SS_{tot} =
$$\sum_{i} (y - \hat{y}_{cp})^2$$
 — общая сумма квадратов,

где
$$y_{cp} = \frac{1}{n} \sum_{i} y_{i}$$

Коэффициент детерминации R2

Расчёт на примере:

пусть

Υ	Υ	mode
-	· _	

1

2 3

3

Сумма квадратов остатков регрессии

$$Ss_{res} = (1-1)^2 + (2-3)^2 + (3-3)^2 = 1$$

Для вычисления общей суммы квадратов потребуется у_{ср} :

$$y_{cp} = (1 + 2 + 3)/3 = 2$$

Тогда общая сумма квадратов:

$$SS_{tot} = (1-2)^2 + (2-2)^2 + (3-2)^2 = 2$$

Коэффициент детерминации равен::

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{1}{2} = 0.5$$

Отбор признаков



