


# Градиентный спуск

Елена Кантонистова

Skillbox


# Как искать минимум функции?



Изображение: работа спикера

# Градиент функции


Градиент — вектор, в направлении которого функция быстрее всего растёт.



Изображение: работа спикера


# Градиент функции

Градиент — вектор, в направлении которого функция быстрее всего растёт.




# Градиент функции

Вычисляем градиент функции в точке и сдвигаемся в противоположном ему направлении.




# Пример

Вычисляем градиент функции в точке и сдвигаемся в противоположном ему направлении.



# Пример

Вычисляем градиент функции в точке и сдвигаемся в противоположном ему направлении.




# Формула градиентного спуска

Вычисляем градиент (в одномерном случае — произвольную) функции  $Q(w)$  в точке и сдвигаемся в противоположном ему направлении:

$$w_{new} = w_{old} - Q'(w_{old})$$



# Градиентный шаг



Добавляем в формулу гиперпараметр  $\alpha$  — шаг градиентного спуска:

$$w_{new} = w_{old} - \alpha \cdot Q'(w_{old})$$

# Градиент

- **Градиент** функции  $Q(w)$  — это вектор

$$\nabla Q(w) = \left\{ \frac{\partial Q}{\partial w_0}, \frac{\partial Q}{\partial w_1}, \dots, \frac{\partial Q}{\partial w_d} \right\},$$

где  $w = (w_0, w_1, \dots, w_d)$

- Вектор  $-\nabla Q(w)$ , противоположный градиенту, называется **антиградиентом**

# Формула градиентного спуска

В случае, если  $Q(w)$  — функция многих переменных, т. е.  $w$  — это не одно число, а вектор  $w = (w_0, w_1, \dots)$ :

$$w_{new} = w_{old} - \alpha \cdot \nabla Q(w_{old})$$

# Недостатки градиентного спуска

$$w_{new} = w_{old} - \alpha \cdot \nabla Q (w_{old})$$

На каждой итерации вычисляем градиент, т. е. производные по всем параметрам и для каждого объекта:

- большие временные затраты
- большие затраты по памяти

# Стохастический градиентный спуск

На каждой итерации:


- выбираем случайный объект обучающей выборки  $x_i$
- вычисляем градиент только на этом объекте:

$$\mathbf{w}_{new} = \mathbf{w}_{old} - \alpha \cdot \nabla Q(\mathbf{w}_{old})$$


где  $\nabla Q_i(\mathbf{w}_{old}) = \nabla Q(\mathbf{w}_{old}, x_i, y_i)$

# GD vs SGD

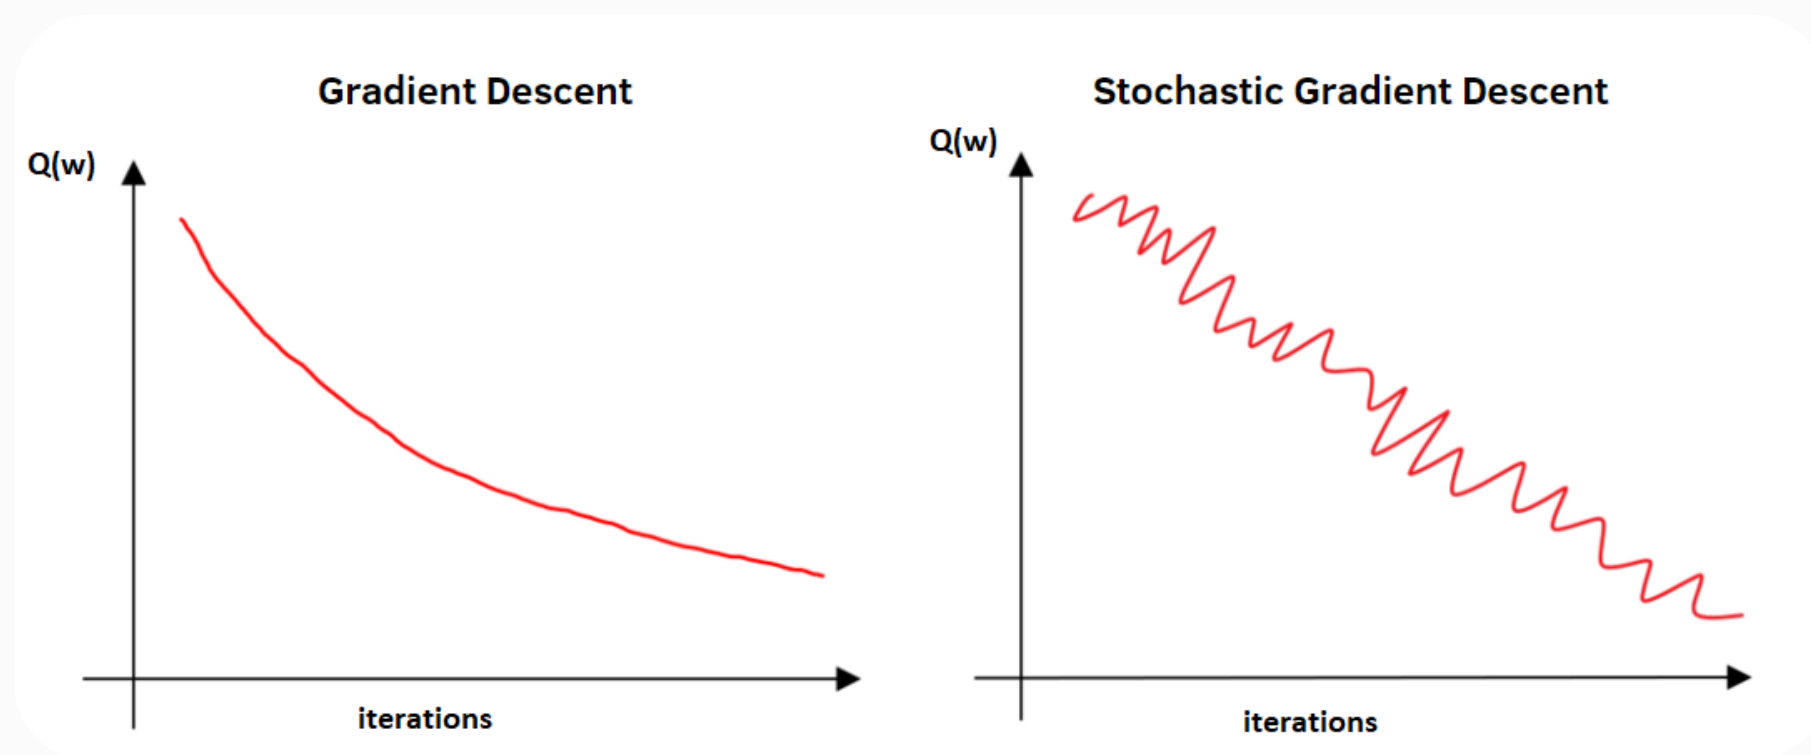
**Gradient Descent**



**Stochastic Gradient Descent**



# GD vs SGD



# Стохастический градиентный спуск

**Утверждение.** Метод стохастического градиентного спуска найдёт локальный минимум функции так же успешно, как и градиентный спуск, в случае, если минимум есть.

Стохастическому градиентному спуску может потребоваться больше итераций, однако он гораздо менее затратный по ресурсам.